

黄欣雨

18800101712 | fugitive_unik@163.com | 中共党员

Web: <https://fugitive-unik.github.io/>



教育经历

香港中文大学 (QS 18)	硕士	统计与数据科学	2025.09-2026.11
GPA: 3.725/4			
专业课程: 高级统计推断(A, PhD水平)、机器学习(A-)、数据优化(A-)、线性模型(A-)、贝叶斯统计与应用(A-)			
东北大学 (985)	本科	应用统计学	2021.09-2025.07
GPA: 3.9/5 (专业第5)			
专业课程: 生物统计(99)、时间序列分析(98)、概率论(97)、贝叶斯统计(96)、统计实务(95)、统计计算与软件(92)			
荣誉&奖项: 美烨基金奖学金(1/3100); 校优秀毕业生; 多次获得五四表彰(优秀团干部标兵)、校三好学生等荣誉; 多次获得校级奖学金			

项目经历

《A SQL-Based Hybrid Database-Driven Framework for Customer Satisfaction Prediction with Machine Learning and Natural Language Processing -Enhanced Sentiment Analysis》	2025.09-2025.11
- 使用SQL对电商数据库的8张核心表进行逆向工程与重构, 设计ER图并整合订单、支付、物流及评论数据, 构建了统一的分析视图; 完成包括缺失值处理、异常订单剔除及基于业务逻辑的特征衍生(如运费效率比、产品体积), 构建高质量的建模数据集 - 构建预测流水线, 对比Ridge Regression、RF和XGBoost三种模型。通过SHAP值与互信息法进行特征重要性分析与筛选, 最终Random Forest模型表现最优, 精准量化了物流时效与支付金额对用户评分的非线性影响机制 - 实现了完整的NLP流程, 包括葡萄牙语文本清洗(去噪、词干提取)、停用词过滤及TF-IDF向量化。对比MultinomialNB、Logistic Regression和RF, 最终选择Logistic Regression部署, 因其在保持高准确率(89.28%)的同时, 具备极佳的模型可解释性 - 结合RFM模型与EDA分析, 揭示平台用户留存率低、地域发展不均及过度依赖信用卡支付的风险。提出“高价值订单延迟赔付”、“运费占比阈值控制”及“沉睡用户唤醒”等数据驱动的运营策略, 指导业务优化用户体验	
《Horse Racing Prediction Based on PPCA and GLM》	2025.11-2026.01
- 对原始53维特征的清洗与重构, 实施赛道特异性分区策略(HV/AVT/ST)以消除场地异质性; 设计基于同场赛事的动态归一化算法, 在保留马匹相对竞技状态的同时, 确保模型输入数据的独立同分布特性, 阻断数据泄露风险 - 针对新马历史特征全缺失的冷启动难题, 利用PPCA(概率主成分分析)的概率生成框架, 通过EM算法基于已知信息(如骑师、档位)推断高维潜变量, 实现无偏降维; 根据赛马数据具有明显的嵌套结构, 通过构建GLMM模型, 分离由特定比赛日天气或场地带来的系统性偏差与马匹自身的竞技状态, 解决传统回归模型中残差独立性假设被违反的问题, 为赛马冠军预测提供稳健的决策依据	

科研经历

《A Theoretical Understanding of Vision Transformers from a Foundation Model Perspective》	2026.01-2026.04
- 基于二分类模型对浅层单头和多头ViT进行理论研究。揭示对于单头ViT, 实现零泛化误差所需的样本复杂度对相关标签比例平方的倒数、标签中的噪声水平以及初始化误差呈正相关。此外, 适当去除无关标签和噪声标签在一定程度上可以提高模型性能。对于多头ViT, 增加注意力头的数量可以降低实现零泛化误差所需的样本复杂度, 特别是在信息量稀疏的标签或噪声水平较高的场景中, 并且选择与目标任务相匹配的头数可以带来更好的性能 - 仿真实验中, 验证单头ViT的四个结论; 且当相关标签的比例降低时, 多头ViT所需的样本复杂度会呈指数级增长	
《基于震荡数据的Conformable型与Caputo型灰色模型对比研究》	第一作者 2025.01-2025.05
- 引入Conformable定义的分数阶累加算子, 推导其系数简化形式, 建立CoFGM(r,1)模型; 在实证分析中验证其可以在迭代过程中可快速识别数据突变。通过Caputo定义的分数阶累加算子, 揭示阶数与新信息优先性的关系; 通过拉普拉斯变换构建CaFGM(r,1)模型, 算例分析证实该模型能够融合全局历史信息, 展现出独特的长记忆性 - 构建多时间尺度振荡数据集, 并对GM(1,1)、CoFGM(r,1)和CaFGM(r,1)进行了系统比较; 结果表明, CoFGM(r,1)实现了最佳的灵敏度以及效率平衡, 且在非平稳和振荡场景中均表现最佳	
《A Functional Data Classification Model Utilizing Functional Mahalanobis Distance and Regenerative Kernel Methods》	第一作者 2023.06-2023.08
- 在预测变量是一个随机函数, 响应变量是离散型标量的情形下, 开发出一种基于函数型马氏距离和再生核理论的函数型数据的相似性度量方法, 并将其用到主成分分析中, 其可以结合支持向量机、随机森林等经典分类算法完成对函数型数据的分类任务 - 实证分析中, 相比基于欧氏距离的再生核以及基于B样条基函数的欧式距离再生核, 该分类方法精确度高达90%	

竞赛经历

2024年国际大学生建模竞赛(美赛)	国际一等奖(队长)	2024.02
通过基于ABM的Logistic模型探究了七鳃鳗性别比例与食物供应和繁殖率之间的关系; 在此基础上建立了EWM模型探究了七鳃鳗繁殖的8种因素优劣性; 创新的构建了基于Logistic的多物种宿主寄生模型以及多寄生虫食物网模型, 探讨了七鳃鳗性别比例变化对于生态环境的影响以及寄生虫对于七鳃鳗种群的影响。		
2023年国际大学生建模竞赛(美赛)	国际二等奖(队长)	2023.02
对Wordle游戏原始数据进行预处理, 用K-means将数据进行分类, 基于新数据采用了ARIMA与GM(1,1)、基于GBDT的SVM模型分别进行数据预测以及分类后数据的难度估算, 并基于划分的数据不同属性采用PCA进行归因。		
2023年APMCM亚太地区数学建模竞赛	国际二等奖(队长)	2023.11
采用灰色关联分析筛选出主要影响新能源汽车发展的因素, 并应用TOPSIS熵权分析进行因素打分, 深入分析不同主要因素的影响; 基于收集的数据采用差分的ARIMA模型对未来发展趋势进行预测; 通过皮尔逊相关系数对传统能源汽车进行因果分析, 并建立热力学模型对比燃油车和新能源车的污染情况。		

校园经历

东北大学总办	第17届学生校长助理	2023.12-2024.12
- 对接各部门, 根据学生提出的问题展开调研并寻求解决方式, 向校领导提交处理建议、向学生反馈校方解决措施 - 针对学生提出校园网络不便问题, 展开实地、问卷等调研, 寻求校网络中心支持, 推动校园网升级改造更新迭代, 最终支持100%宿舍覆盖率		
东北大学数学与统计学院	学生会主席、党校副校长	2022.11-2023.11
- 策划并开展数统学子“与”系列共计8个活动, 参与人次达500次 - 策划并开展东北大学第十六届“东采杯”校史校情知识竞赛初赛和决赛, 参与活动人数超过800人 - 策划并开展学院入党积极分子培训, 协助老师授课, 监督党课制定和结业考核, 累计培训五期共200名党校学员		

技能与专长

- 语言类: 雅思6.5、CET-6, 听说读写流利, 英文可作为工作语言
- 数据分析与处理: SQL、R、Python(毕设使用)、SPSS、SAS
- 办公软件: 熟练使用Excel(数据透视、Vlookup)、PowerPoint、Word、飞书、钉钉等软件, 可以用LATEX写作